

Colorectal cancer classification using Deep Convolutional Networks

An experimental study

BAZIÉ Dureel
BICABA Hawahoun Pauline
COULIBALY Cheick Ahmed
KOALA Valentin
TRAORÉ Soungalo

Université Virtuelle du Burkina Faso (UVBF)

4 Septembre 2025

Plan de la Présentation

1 Présentation du problème

2 Méthode Proposée

3 Expériences et Résultats

4 Conclusion et discussion

Contexte médical

- **Cancer Colorectal (CRC)** : contraction des mots ‘côlon’ et ‘rectum’, c'est lorsque des cellules du côlon ou du rectum se multiplient pour former une tumeur cancéreuse. Un des cancers les plus répandus mondialement
- Cause majeure de décès liés au cancer
- **Diagnostic traditionnel** : examen visuel microscopique des tissus H&E

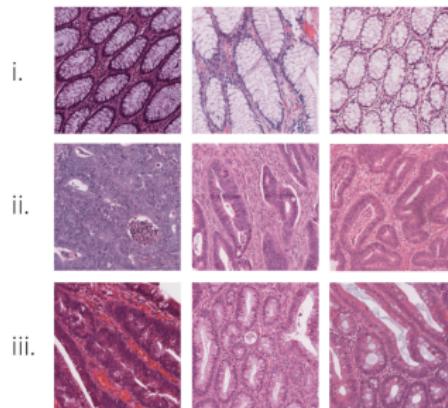


Figure 1: Histological H&E images of colorectal tissues (cropped patches). i) Healthy tissue; ii) Adenocarcinoma; iii) Tubulovillous adenoma.

Problèmes du diagnostic traditionnel

Limites des méthodes actuelles

- **Chronophage** : surtout pour de grandes bases de données
- **Subjectivité élevée** :
 - Variabilité inter-observateur
 - Variabilité intra-observateur
- **Besoin d'expertise** : pathologistes qualifiés

Objectif de l'étude

Développer un système automatisé pour classifier 3 catégories :

- ① Tissu sain (H)
- ② Adénocarcinome (AC) - cancéreux
- ③ Adénome tubulovilleux (TV) - bénin

Données utilisées

- **Source :** Repository public (Leeds University)
- **Données :** 27 images WSI (Whole Slide Image = image de lame entière) de tissus colorectaux H&E
- **Extraction :** 13,500 patches de 1089×1089 pixels
- **Grossissement :** 40x

	Train	Test	Total
Patients	18	9	27
ROIs	85	24	109
Patches	9000	4500	13500

Table – Répartition du dataset

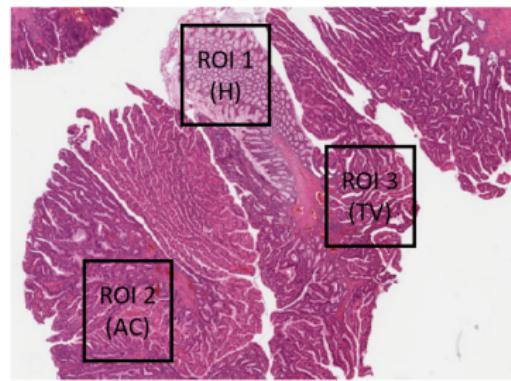


Figure – Identification des ROI sur WSI

Prétraitement des données

Étapes de Préparation

- ① **Sous-échantillonnage** : facteur 5 (compromis calcul/détail)
- ② **Normalisation** : par moyenne et écart-type du dataset d'entraînement
- ③ **Équilibrage** : échantillonnage stratifié pour les 3 classes

Justification du prétraitement

- Réduction de la charge computationnelle
- Compensation des inconsistances de couleur
- Assurance d'un dataset équilibré pour l'entraînement

Architecture VGG16

Pourquoi VGG16 ?

- CNNVGG16 : Convolutional Neural Network Visual Geometry Group
- Compromis optimal : représentation vs. coût
- Architecture simple et éprouvée
- Succès dans de nombreuses tâches de vision

Structure

- 13 couches CONV (3×3)
- 5 couches POOL (2×2)
- 3 couches FC
- Activation : ReLU + Softmax finale

Architecture VGG16

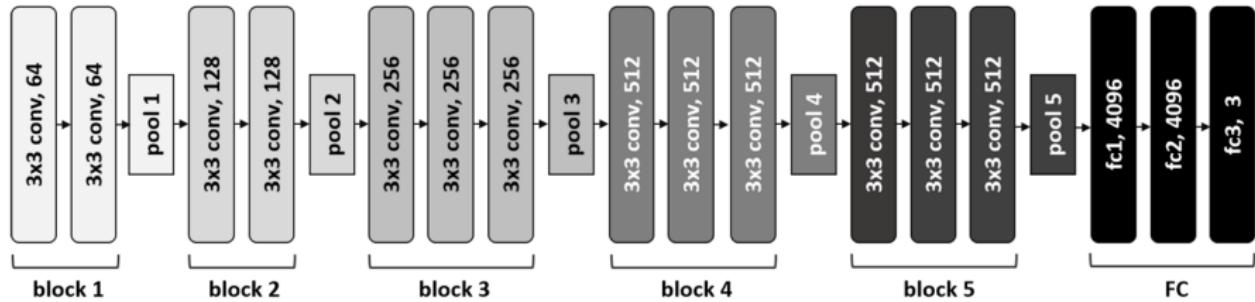


Figure – Architecture VGG16

Paramètres d'Entraînement

Paramètre	Valeur
Optimiseur	SGD avec momentum
Taux d'apprentissage (LR)	0.0001
Momentum	0.9
Taille de batch	32
Fonction de perte	Cross-entropy catégorielle
Époques	30
Validation	10% du dataset d'entraînement
Early stopping	10 époques sans amélioration

Table – Hyperparamètres d'entraînement

- **Durée** : 8 heures sur GPU (NVIDIA Tesla K40)
- **Techniques** : Early stopping + réduction progressive du LR

Transfer Learning

Motivation

CNN pré-entraîné sur ImageNet (1.2M images, 1000 classes)

Approche 1 : Feature Generator

- ① Extraction features via POOL3
- ② Réduction PCA (250 composantes)
- ③ Classification SVM (RBF kernel)
- ④ Optimisation bayésienne des hyperparamètres

Approche 2 : Fine-tuning

- ① Initialisation : poids ImageNet
- ② Gel des poids jusqu'à POOL3
- ③ Réentraînement couches supérieures
- ④ Durée : 2h vs 8h (entraînement complet)

Sélection de POOL3

Confirmée par analyse t-SNE : meilleure séparabilité des classes

Métriques d'évaluation

Scores de Performance

- **Patch Score (S_P) :**

$$S_P = \frac{N_C}{N}$$

où N_C = patches correctement classifiés, N = total patches

- **Patient Score (S_{Pt}) :**

$$S_{Pt} = \frac{\sum_i S_P(i)}{N_P}$$

où $S_P(i)$ = score du patient i , N_P = nombre total de patients

Justification

- Évaluation à deux niveaux d'abstraction
- Robustesse inter-patient
- Dataset de test complètement indépendant

Résultats comparatifs

Méthode	Patch Score	Patient Score
CNN Entraînement complet	90.37%	90.22% ($\pm 1.55\%$)
CNN+SVM (Transfer Learning)	96.46%	96.67% ($\pm 0.82\%$)
Fine-tuning CNN	96.82%	96.78% ($\pm 0.09\%$)

Table – Performances de classification sur le dataset de test

Observations clés

- Transfer Learning surpassé l'entraînement complet de 7%
- Faible écart-type → excellente robustesse inter-patient
- Fine-tuning = meilleure approche

Analyse des résultats par classe

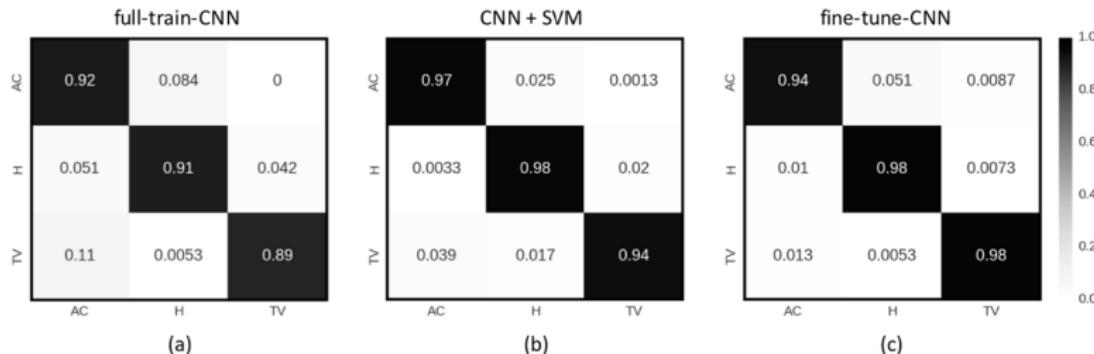


Figure 8: Patch-wise confusion matrices for (a) CNN fully trained on CRC samples, (b) SVM with pre-trained CNN as fixed features generator, (c) pre-trained CNN with fine-tuning of the stages after POOL3 block.

CNN complet CNN+SVM Fine-tuning

Figure – Matrices de confusion pour les trois approches

- Performance homogène sur les 3 classes (H, AC, TV)
- Réduction significative des erreurs avec transfer learning
- Fine-tuning montre la meilleure cohérence

Analyse de profondeur optimale

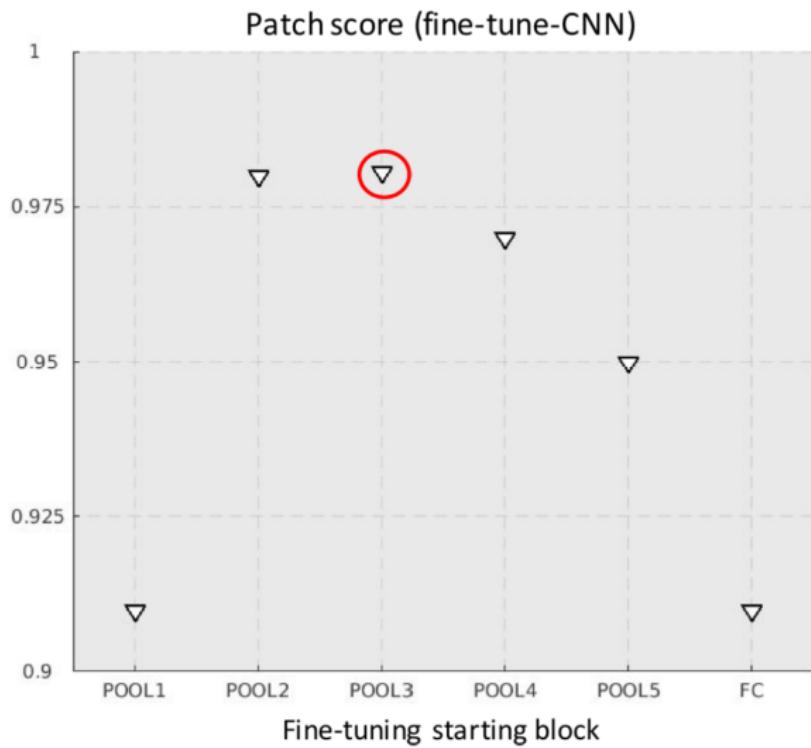


Figure – Accuracy vs point de départ du fine-tuning

Applicabilité au Burkina Faso

Avantages potentiels

- Réduction subjectivité diagnostique
- Accélération du diagnostic
- Formation des pathologistes
- Telemédecine possible
- Diagnostic standardisé

Défis à relever

- **Données** : Images locales annotées
- **Infrastructure** : Équipements numériques
- **Formation** : Personnel qualifié
- **Validation** : Adaptation population locale
- **Coûts** : Implémentation et maintenance

Stratégie d'implémentation proposée

- ① **Phase pilote** : Partenariat avec CHU-YO/CHUSS
- ② **Collecte de données** : Constitution dataset burkinabé
- ③ **Adaptation** : Fine-tuning sur données locales
- ④ **Formation** : Pathologistes et techniciens
- ⑤ **Validation** : Étude comparative avec diagnostic manuel
- ⑥ **Déploiement** : Extension progressive aux centres régionaux

Ressources Nécessaires

- Microscopes numériques haute résolution
- Serveurs avec GPU pour l'entraînement
- Logiciel de gestion d'images médicales
- Programme de formation spécialisé

Améliorations possibles

Extensions Techniques

- **Plus de classes** : autres lésions bénignes
- **Architectures récentes** : ResNet, EfficientNet
- **Attention mechanisms** : localisation des régions critiques
- **Segmentation automatique** : identification ROI

Améliorations méthodologiques

- **Augmentation de données** : rotations, translations
- **Ensemble methods** : combinaison de modèles
- **Explicabilité** : visualisation des décisions
- **Apprentissage multi-échelle** : différents grossissements

Conclusion générale

Contributions de l'Étude

- Démonstration efficacité des CNN pour classification CRC
- Transfer learning > entraînement complet (96.8% vs 90.4%)
- Fine-tuning = approche optimale (temps + performance)
- Robustesse inter-patient confirmée

Perspective Burkina Faso

- **Faisable** avec infrastructure adaptée
- **Utile** pour améliorer diagnostic oncologique
- **Nécessite** partenariat institutionnel fort
- **Potentiel** d'extension à d'autres cancers

L'IA peut révolutionner le diagnostic médical en Afrique !

Questions & Réponses

Merci pour votre attention !